

PUCP · SEMINARIO DE DEEP LEARNING APLICADO A BIOANÁLISIS

Segmentación semántica de núcleos con U-Net

Módulo 2 · Dataset PanNuke · Dice + BCE Loss



Integrantes

Divano Perez

Jorge Vicente

Angel Sánchez

Alfredo Sánchez

Yulissa Pelaez

Lima, Perú



Agenda

01

Problema y objetivos

Por qué automatizar la segmentación de núcleos y qué exige el Módulo 2.

02

Dataset

PanNuke: composición, escala y partición usada para entrenar y evaluar.

03

Metodología

Arquitectura U-Net desde cero, función de pérdida y aumentación de datos.

04

Resultados y conclusiones

Métricas Dice / IoU, ejemplos cualitativos y trabajo futuro.



El problema clínico


En patología digital, contar y delimitar núcleos celulares en imágenes histológicas (tinción H&E) es un paso previo para el diagnóstico y graduación de tumores.

Hacerlo manualmente es lento y depende del observador. Un modelo de segmentación semántica entrenado sobre miles de parches anotados puede delimitar núcleo vs. fondo de forma automática y consistente.



Meta del proyecto

Entrenar una U-Net que, a partir de una imagen H&E de 256×256, prediga la máscara binaria núcleo / fondo.





Objetivos del Módulo 2



Arquitectura desde cero

U-Net en PyTorch: Encoder, Bottleneck, Decoder y Skip Connections.



Pérdida compuesta

Dice Loss + BCE Loss para manejar el desbalance espacial núcleo/fondo.



Evaluación cuantitativa

Coeficiente de Dice (DSC) e Intersección sobre Unión (IoU / Jaccard).



Datos y aumentación

DataLoaders con aumentación síncrona: volteos y rotaciones simétricas.

Especificación del curso — repositorio dlba-pucp (github.com/alexandrojim/dlba-pucp), Módulo 2: Segmentación Semántica (U-Net & Métricas de Forma).



Dataset: PanNuke

PanNuke (Gamper et al., 2019–2020) reúne parches H&E de 19 tipos de tejido con anotaciones a nivel de núcleo — mayor diversidad tisular que alternativas de un solo tejido como 2018 Data Science Bowl o MoNuSeg.

Este proyecto aborda la variante binaria del problema: cada píxel se clasifica como núcleo o fondo, a partir de las máscaras oficiales consolidadas en un único canal.

Partición: 90/10 (train/val) sobre train/, más validate/ completo como test independiente — semilla fija (42) para reproducibilidad.

19

tipos de tejido

7,901

parches 256×256 @ 40×

6,716

pares train


1,185

pares test (validate/)




Exploración visual y feature engineering


Imagen H&E original




Bordes (Sobel)



Umbral de Otsu
(canal hematoxilina)



Textura local (LBP)




Filtros clásicos aplicados sobre un parche real de PanNuke (train/, alta densidad nuclear) antes de decidir el preprocesamiento del modelo.

- Sobel resalta bordes de membrana nuclear y solapamientos entre núcleos contiguos.
- Otsu sobre el canal hematoxilina (B-R) da una segmentación clásica ruidosa — motiva usar un modelo aprendido en vez de un umbral fijo.
- LBP expone la microtextura de la cromatina, relevante para distinguir atipia nuclear.



Arquitectura: U-Net desde cero (PyTorch)





Entrenamiento y aumentación de datos

Función de pérdida

`BCEWithLogitsLoss + DiceLoss`

La componente Dice compensa el fuerte desbalance espacial entre píxeles de núcleo y de fondo.

Hiperparámetros

Optimizador **Adam**


Learning rate **$1e-3$**

Batch size **8**

Épocas **15**

Aumentación síncrona (train)

Flip horizontal · flip vertical · rotación 90/180/270° — aplicadas igual a imagen y máscara.



Curva de pérdida / métrica por época (train vs. validación).

Checkpointing: se guarda best_model.pt cada vez que mejora Val Dice. No se usó early stopping — límite fijo de 15 épocas, consistente con la curva de validación aún sin señal clara de sobreajuste.



Resultados cuantitativos

0.828

Dice (DSC) — test

0.723

IoU (Jaccard) — test

15

épocas entrenadas

≈105 min

tiempo de entrenamiento
(GPU)



La comparación contra el modelo base (model.h5) se omitió en esta corrida por una incompatibilidad de la capa Conv2DTranspose entre el .h5 original y Keras 3 (registrado en metrics_summary.json).



Resultados cualitativos




Imagen H&E · Máscara real · Probabilidad U-Net · Predicción binaria

- En regiones densas de núcleos, la predicción cubre casi todos los núcleos visibles en la máscara real.
- Los núcleos alargados y de bajo contraste (fila superior) son el caso más difícil: el modelo tiende a omitirlos.
- En clusters muy juntos aparece fragmentación menor en los bordes de contacto entre núcleos.



Conclusiones y trabajo futuro

Conclusiones

- Una U-Net construida desde cero (7.9M parámetros aprox., 4 niveles) alcanza Dice 0.828 / IoU 0.723 en segmentación binaria de núcleos sobre PanNuke.
- La pérdida compuesta Dice + BCE, junto con aumentación síncrona, entrena de forma estable en solo 15 épocas, evaluada en el split test independiente (validate/, 1,185 pares).
- Limitación: PanNuke mezcla 19 tejidos con variabilidad de tinción H&E entre laboratorios; ese sesgo de dominio no se evaluó explícitamente en esta corrida.

Trabajo futuro

- Extender a segmentación multiclase (5 tipos nucleares + fondo) usando las etiquetas completas de PanNuke.
- Post-procesamiento por watershed para pasar de máscara semántica a instancias individuales (PQ / AII).
- Validación cruzada con los 3 folds oficiales de PanNuke, y comparación formal contra el baseline.

¡Gracias! Preguntas y comentarios.

Divano Perez · Jorge Vicente · Angel Sánchez · Alfredo Sánchez · Yulissa Pelaez